

# WSI laboratorium 5 – Sprawozdanie

Pryimak Andrii-Stepan 336173


Brózdziński Bartosz 331363

## Wprowadzenie

Celem ćwiczenia było zaimplementowanie perceptronu dwuwarstwowego i nauczenie go aproksymacji funkcji  $J(x)$  zdefiniowanej wzorem:

$$J(x) = \sin\left(x\sqrt{p[0] + 1}\right) + \cos\left(x\sqrt{p[1] + 1}\right)$$

gdzie  $p = [3,3]$  to najmłodsze cyfry numerów indeksów wykonawców. Zadanie obejmowało ocenę jakości aproksymacji oraz analizę wpływu liczby neuronów w warstwie ukrytej na tę jakość.



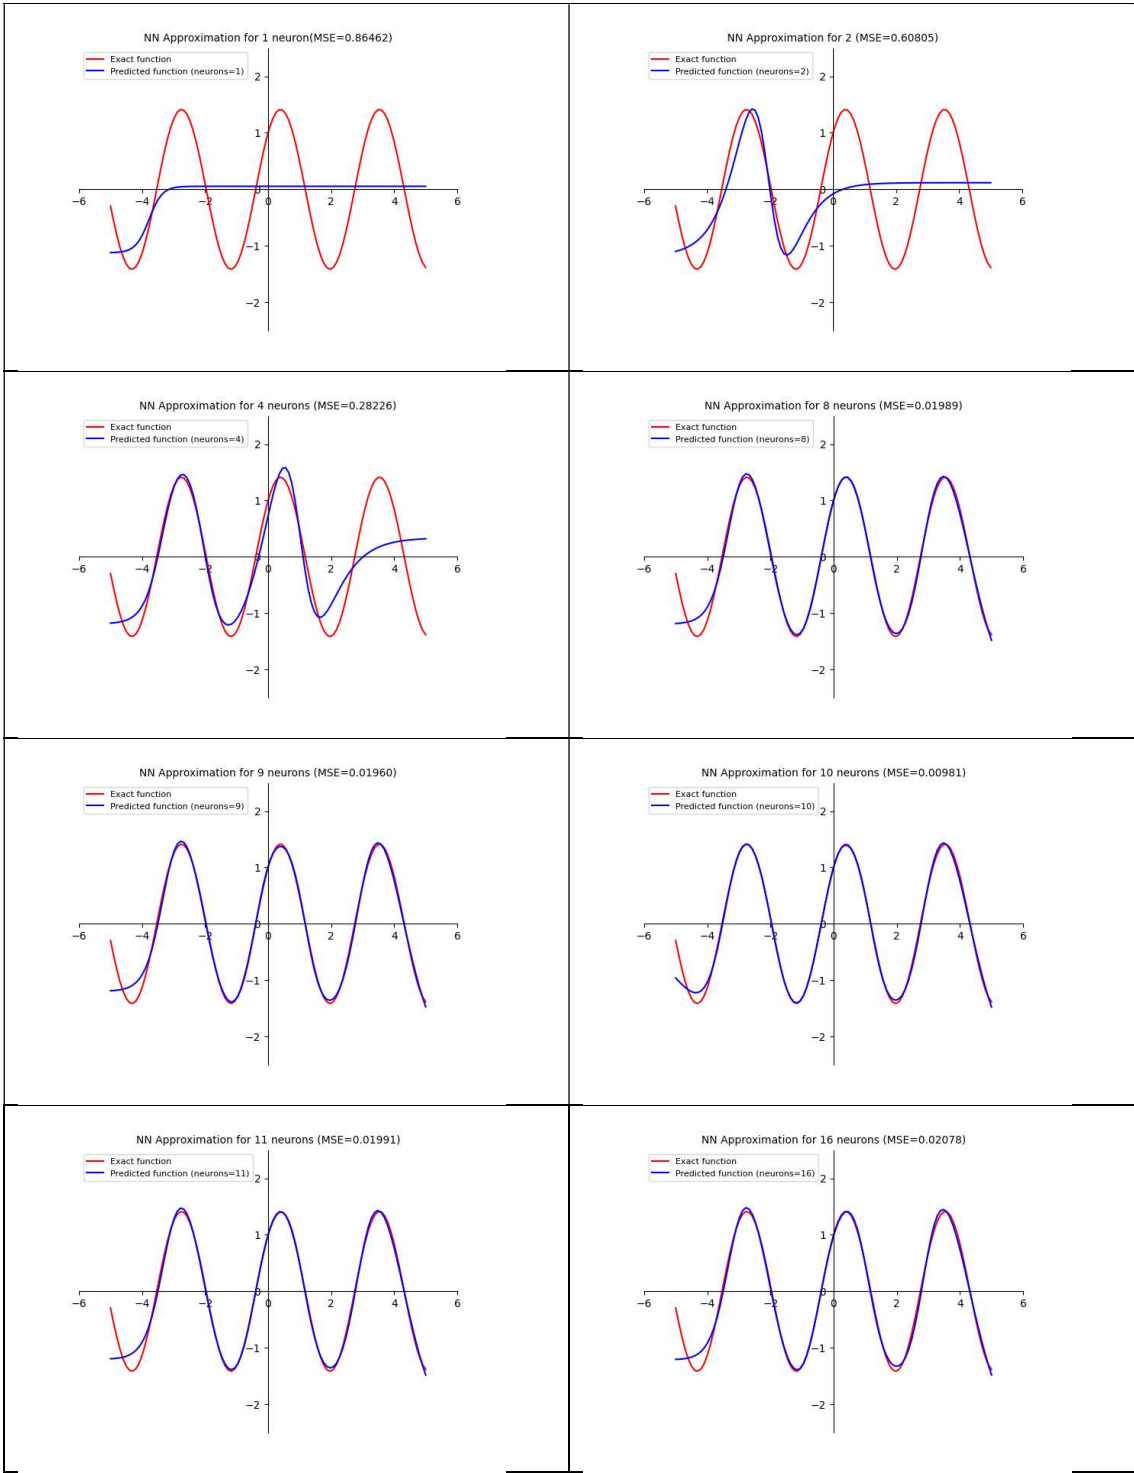
## Jakość aproksymacji

Funkcja straty:  $q(y) = |y - y_d|^2$

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - y_{d,i})^2$$

Jakość funkcja aproksymacji oceniana przez średni błąd kwadratowy.

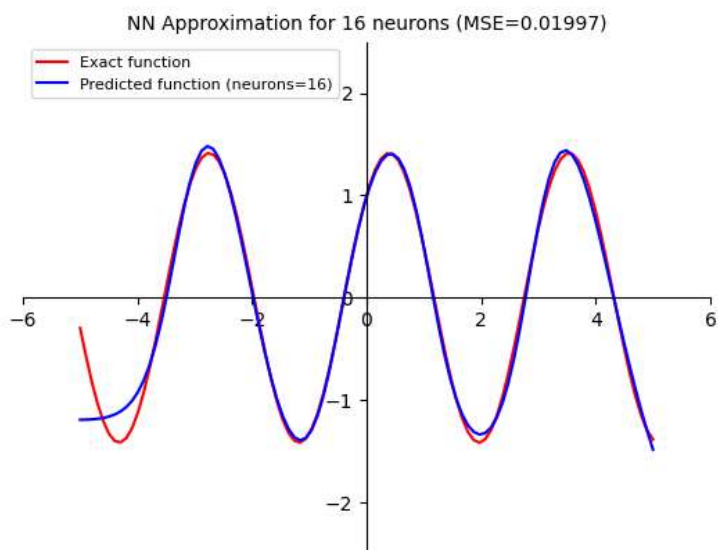
Wyniki




Liczba neuronów	Iteracje	MSE
1	15000	0,8646178961814479
2	15000	0,6080473944668907
4	15000	0,2822586089682772
8	15000	0,019888161239076527
9	15000	0,01959910126311165
10	15000	0,00981236703255499
11	15000	0,01990872188822159
16	15000	0.01996544163969361
16	30000	0,01213
16	60000	0.007582265230183606
32	15000	0,02030
32	30000	0,00253
32	60000	0,00090
64	15000	0,25665
64	30000	0,00743
64	60000	0,00113

Z analizy wyników wynika, że zwiększenie liczby neuronów w warstwie ukrytej znacząco poprawia jakość aproksymacji, co objawia się niższym błędem MSE. Jednakże dla bardzo dużej liczby neuronów sieć może mieć problem z nauczeniem się, jeśli liczba iteracji nie jest wystarczająca.


15k MSE =0,01996544163969361




30k MSE = 0,01213




60k MSE =0,007582265230183606




32 neurony, 15000 iteracji



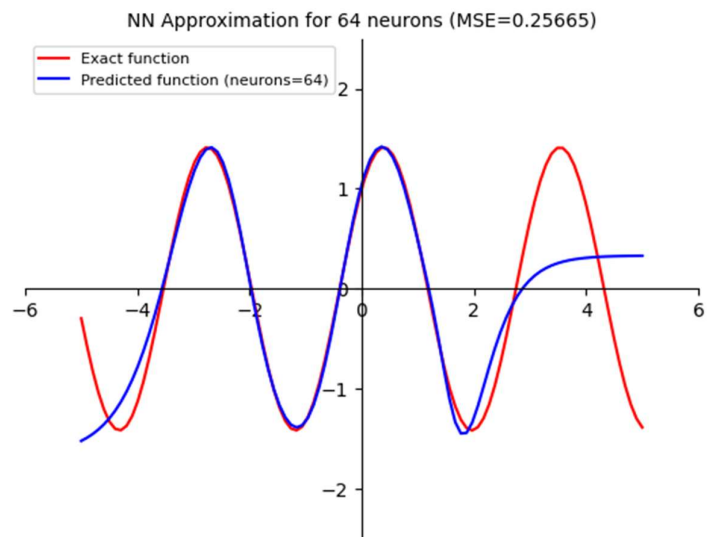
32 neurony, 30000 iteracji



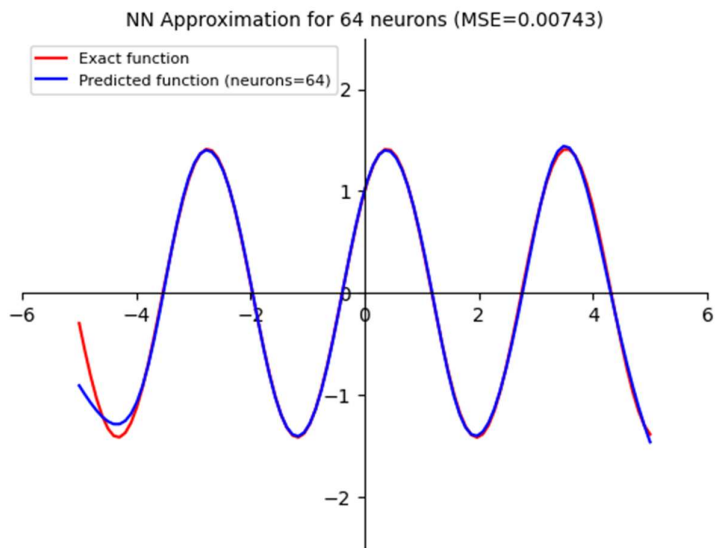
32 neurony, 60000 iteracji




64 neurony, 15000 iteracji



64 neurony, 30000 iteracji



64 neurony, 60000 iteracji



## Wnioski

Dwuwarstwowy perceptron dobrze radzi sobie z aproksymacją funkcji  $J(x)$ , osiągając niski błąd przy odpowiednio dobranej liczbie neuronów. Zwiększenie liczby neuronów poprawia jakość aproksymacji, ale kosztem wzrostu czasu uczenia. Jednakże, jak widać na poniższym wykresie, nie zawsze zwiększenie liczby neuronów poprawi wyniki. Dla dużych ilości neuronów dobre nauczanie się aproksymacji zajmuje więcej iteracji, ponieważ co każdą z nich musimy dostosowywać więcej zmiennych. Przez to zwiększenie liczby neuronów powinno być powiązane ze zwiększeniem liczby iteracji, jeśli zauważamy spadki wartości wykresu. Na przykład, dla naszego przykładu, dla 15000 iteracji zdecydowanie najlepiej radziła sobie sieć złożona z 10 neuronów, a zwiększanie ich ilości pogarszało wyniki. Po zwiększeniu liczby iteracji do 30000, najlepsze przybliżenie uzyskano dla 32 neuronów.

